UJIAN TENGAH SEMESTER

# VISUALISASI DATA

*Laporan Analisis Data*

CASE REPORT

---

## Reliabilitas LLM dalam Menyelesaikan Tugas Sehari-hari dan Teknis secara One-Shot


**NAMA** Sebastian Abe Santoso

**NIM** 2410817210002


**2026**

# HALAMAN PERSEMBAHAN

Dengan segala puji syukur kepada Allah SWT dan atas dukungan dan doa dari orang-orang tercinta, akhirnya dokumen ini dapat dirampungkan dengan baik dan tepat pada waktunya. Oleh karena itu, dengan rasa bangga dan bahagia saya ucapkan rasa syukur dan terimakasih saya kepada:

1. Kepada Allah SWT atas berkat rahmat dan karunia-Nya yang telah memberikan saya kelancaran dan kemudahan dalam menyelesaikan dokumen ini.
2. Teruntuk orang tua saya yang selalu mendukung dan mendo'akan saya disetiap sujudnya. Yang selalu berusaha memberikan yang terbaik untuk saya, terimakasih atas kasih sayangnya selama ini, atas perhatian dan dukungan selama ini. Semoga Allah SWT memberikan JannahNya.
3. Teruntuk kakak saya yang senantiasa memberikan dukungan, semangat, senyum dan doanya untuk keberhasilan ini, terimakasih dan semangat belajar perjalananmu masih panjang di jenjang pendidikan.
4. Teruntuk keluarga yang telah banyak mensupport saya selama ini. Dan yang selalu mendoakan saya untuk bisa terus meraih pendidikan yang setinggi-tingginya. Selalu mengingatkan saya hal-hal yang boleh dilakukan dan tidak boleh dilakukan. Terimakasih support kalian karena support itu saya bisa lebih giat lagi meraih cita-cita saya.
5. Teruntuk teman-teman saya yang menjadi salah satu support sistem saya setelah keluarga. Orang pertama yang selalu ada disaat saya membutuhkan support dalam segala hal. Menjadi orang paling peduli untuk saya dan yang selalu cerewet kepada saya untuk segera menyelesaikan skripsi ini. Terimakasih sudah menemani dalam hal akademis dan non-akademik.
6. Bapak, Ibu Dosen pengampu, dan pengajar, yang selama ini telah tulus dan ikhlas meluangkan waktunya untuk menuntun dan mengarahkan saya, memberikan pelajaran yang tiada ternilai harganya, agar saya menjadi lebih baik. Terimakasih banyak Bapak dan Ibu dosen, jasa kalian akan selalu terpatri di hati.

# DAFTAR ISI

HALAMAN PERSEMBAHAN ..... 2

DAFTAR ISI ..... 3

DAFTAR GAMBAR ..... 4

DAFTAR TABEL ..... 5

DAFTAR LAMPIRAN ..... 6

KONTEN ..... 7

1. Judul ..... 7
2. Urgensi ..... 7
3. Rencana Dataset ..... 8
4. Jumlah Dataset Sementara ..... 9
5. Rencana Visualisasi ..... 11
6. Tools yang Digunakan ..... 11
7. Rencana Visualisasi yang dapat dibuat ..... 12

DAFTAR PUSTAKA ..... 14

LAMPIRAN ..... 15

# DAFTAR GAMBAR

Gambar 1. Head Dataset..... 10
Gambar 2. Tail Dataset..... 10

# DAFTAR TABEL

Tabel 1. Variabel Utama ..... 9
Tabel 2. Tools Digunakan ..... 11
Tabel 3. Rencana Visualisasi yang Dibuat ..... 12

# DAFTAR LAMPIRAN

# KONTEN

1. Judul

Reliabilitas LLM dalam Menyelesaikan Tugas Sehari-hari dan Teknis secara One-Shot

1.1. Penjelasan Singkat

Penelitian ini bertujuan untuk menganalisis reliabilitas *Large Language Models* (LLM) dalam menyelesaikan tugas sehari-hari dan teknis melalui pendekatan *one-shot*, yaitu dengan memberikan satu prompt tanpa interaksi lanjutan.

Analisis dilakukan dengan membandingkan karakteristik respons dari berbagai model berdasarkan tingkat penyelesaian tugas, latensi, penggunaan token, biaya, dan konsistensi hasil. Hasil analisis diharapkan dapat membantu memahami keandalan dan efisiensi model-model LLM berbeda dalam mendukung berbagai kebutuhan pengguna.

2. Urgensi

2.1 Impact

Penelitian ini diharapkan dapat memberikan gambaran yang lebih terukur mengenai keandalan berbagai model LLM, sehingga pengguna tidak hanya bergantung pada popularitas atau persepsi terhadap suatu model dalam menentukan pilihan. Hasil visualisasi dapat membantu mengidentifikasi perbedaan kinerja antar-model serta kompromi antara kualitas respons, kecepatan, dan biaya. Temuan ini juga dapat menjadi dasar untuk mempertimbangkan penggunaan LLM secara lebih tepat sesuai kebutuhan dan keterbatasan masing-masing model.

2.2 Masalah

Banyaknya pilihan LLM membuat pengguna perlu mempertimbangkan kemampuan dan efisiensi model sebelum menggunakannya untuk kebutuhan tertentu. Namun, perbedaan antar-model tidak selalu mudah dipahami hanya berdasarkan informasi umum atau pengalaman penggunaan secara terbatas.

Permasalahan yang dikaji adalah bagaimana kinerja berbagai LLM berbeda dalam menyelesaikan beragam jenis tugas, serta bagaimana perbedaan tersebut berkaitan dengan waktu respons, penggunaan token, biaya, dan status penyelesaian tugas.

Melalui visualisasi data, perbedaan antar-model dan kategori tugas dapat dibandingkan dengan lebih jelas, pola efisiensi dapat diidentifikasi, serta kasus respons kosong atau terpotong dapat ditinjau untuk memahami keterbatasan penggunaan LLM secara satu prompt.

2.3 Tujuan

Analisis data ini bertujuan untuk membandingkan reliabilitas dan efisiensi 12 LLM dalam menyelesaikan 50 prompt yang mewakili berbagai kategori tugas, dengan masing-masing prompt diuji sebanyak dua kali. Secara spesifik, analisis akan dilakukan untuk:

1. Membandingkan tingkat penyelesaian tugas antar-model berdasarkan status respons, seperti lengkap, kosong, atau terpotong.
2. Mengidentifikasi perbedaan waktu respons, penggunaan token, dan biaya antar-model serta kategori tugas.
3. Menganalisis konsistensi hasil dari dua percobaan pada prompt yang sama.
4. Menyajikan pola perbandingan tersebut melalui visualisasi data untuk membantu memahami kelebihan dan keterbatasan masing-masing model.

3. Rencana Dataset

Nama dataset: One-Shot LLM Task Reliability

Sumber dataset: Data eksperimen yang dikumpulkan secara mandiri melalui OpenRouter API dengan menjalankan prompt terstandarisasi pada berbagai model LLM.

Deskripsi dataset: Dataset terdiri dari 1.200 record hasil eksperimen, yang berasal dari 50 prompt, 12 model LLM, dan dua percobaan untuk setiap kombinasi prompt dan model.

Data mencakup informasi model, kategori tugas, status penyelesaian respons, waktu respons, penggunaan token, biaya aktual, serta teks prompt dan respons.

Prompt mencakup enam kategori, yaitu tugas sehari-hari, kreatif, teknis atau pemrograman, riset atau perbandingan, AI atau machine learning, serta pemecahan masalah atau akademik.

Dataset ini memungkinkan perbandingan kinerja dan efisiensi model berdasarkan indikator yang tercatat.

Dataset utama dievaluasi menggunakan ground truth yang disusun menggunakan Claude (Sonnet 5.5 Medium) dengan memberikan instruksi singkat untuk menghasilkan referensi evaluasi berdasarkan daftar prompt dalam berkas prompt.csv. Ground truth mencakup jawaban referensi, kriteria penerimaan (*acceptance criteria*), dan kesalahan kritis (*critical errors*) yang menjadi acuan dalam penilaian respons model.

Evaluasi respons dilakukan secara otomatis menggunakan skrip Python dengan Xiaomi MiMo-V2.6-Pro sebagai model penilai melalui OpenRouter API. Setiap respons dibandingkan dengan prompt asli, ground truth, kriteria penerimaan, dan daftar kesalahan kritis. Penilaian

menghasilkan skor kualitas pada skala 0–100, label penerimaan biner (0 atau 1), serta alasan penilaian. Respons dinyatakan diterima apabila memenuhi kriteria penerimaan yang esensial dan tidak mengandung kesalahan kritis, sesuai instruksi evaluasi.

Variabel utama adalah sebagai berikut:

*Tabel 1. Variabel Utama*

| VARIABEL | VARIABEL |
|---|---|
| model_name | Nama model LLM yang diuji. |
| prompt_id | Identitas prompt yang digunakan dalam eksperimen. |
| run_id | Identitas percobaan pertama atau kedua. |
| kategori_tugas | Kategori tugas berdasarkan kelompok prompt. |
| completion_status | Status penyelesaian respons, seperti lengkap, kosong, atau terpotong. |
| latency_ms | Waktu respons dalam milidetik. |
| input_tokens | Jumlah token masukan yang digunakan. |
| output_tokens | Jumlah token keluaran yang dihasilkan. |
| actual_cost_usd | Biaya aktual setiap permintaan dalam dolar AS. |
| response | Teks jawaban yang dihasilkan model. |

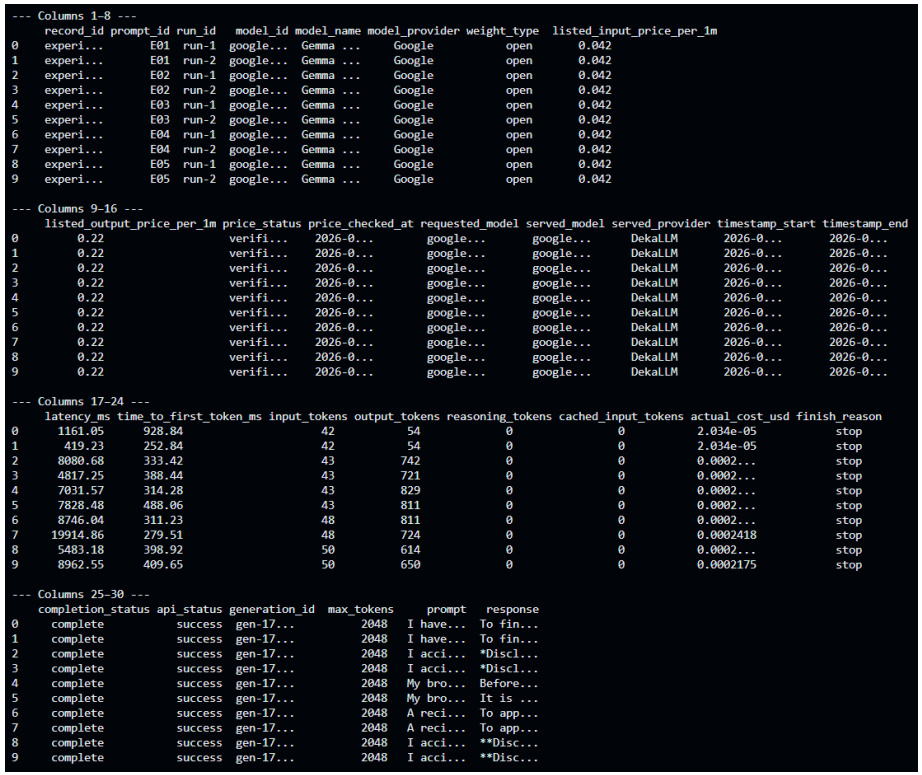
4. Jumlah Dataset Sementara

Jumlah data/record: 1.200 record

Periode data: 25 September 2026 (periode pengumpulan data berdasarkan timestamp UTC)

Jumlah variabel: 30 variabel/kolom (raw memiliki 43), di bawah ini adalah 10 (sepuluh) record dari awal dan akhir dataset.

Head:



```
--- Columns 1–8 ---
     record_id prompt_id run_id   model_id model_name model_provider weight_type  listed_input_price_per_1m
0    experi...       E01  run-1  google...  Gemma ...     Google          open       0.042
1    experi...       E01  run-2  google...  Gemma ...     Google          open       0.042
2    experi...       E02  run-1  google...  Gemma ...     Google          open       0.042
3    experi...       E02  run-2  google...  Gemma ...     Google          open       0.042
4    experi...       E03  run-1  google...  Gemma ...     Google          open       0.042
5    experi...       E03  run-2  google...  Gemma ...     Google          open       0.042
6    experi...       E04  run-1  google...  Gemma ...     Google          open       0.042
7    experi...       E04  run-2  google...  Gemma ...     Google          open       0.042
8    experi...       E05  run-1  google...  Gemma ...     Google          open       0.042
9    experi...       E05  run-2  google...  Gemma ...     Google          open       0.042

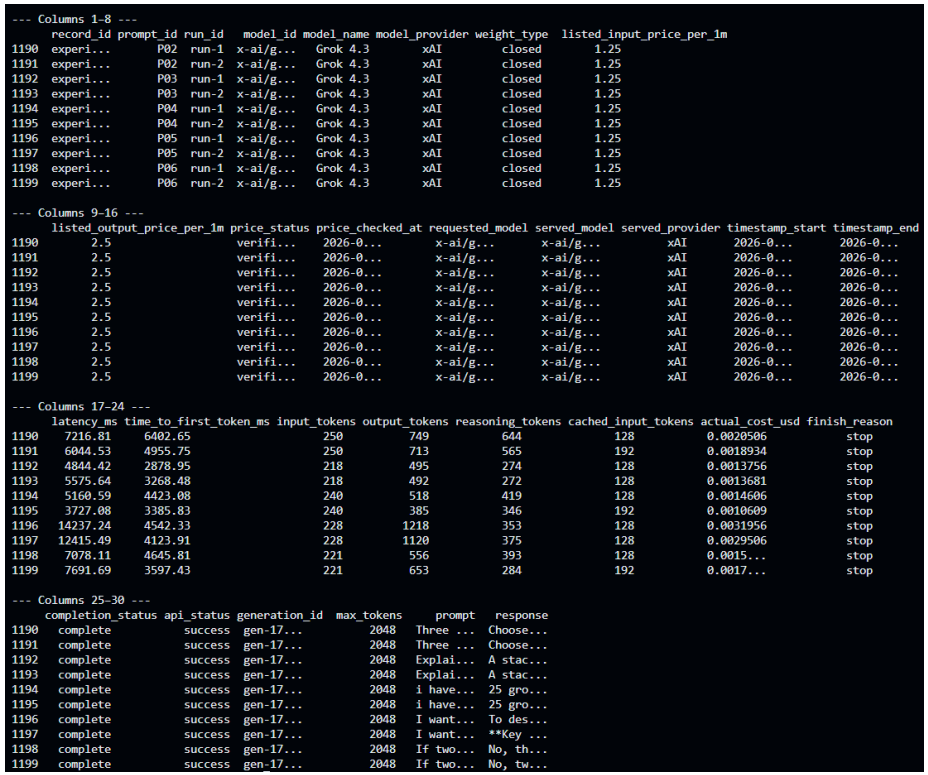
--- Columns 9–16 ---
     listed_output_price_per_1m price_status price_checked_at requested_model served_model served_provider timestamp_start timestamp_end
0        0.22                   verifi...    2026-0...        google...       google...       DekaLLM       2026-0...       2026-0...
1        0.22                   verifi...    2026-0...        google...       google...       DekaLLM       2026-0...       2026-0...
2        0.22                   verifi...    2026-0...        google...       google...       DekaLLM       2026-0...       2026-0...
3        0.22                   verifi...    2026-0...        google...       google...       DekaLLM       2026-0...       2026-0...
4        0.22                   verifi...    2026-0...        google...       google...       DekaLLM       2026-0...       2026-0...
5        0.22                   verifi...    2026-0...        google...       google...       DekaLLM       2026-0...       2026-0...
6        0.22                   verifi...    2026-0...        google...       google...       DekaLLM       2026-0...       2026-0...
7        0.22                   verifi...    2026-0...        google...       google...       DekaLLM       2026-0...       2026-0...
8        0.22                   verifi...    2026-0...        google...       google...       DekaLLM       2026-0...       2026-0...
9        0.22                   verifi...    2026-0...        google...       google...       DekaLLM       2026-0...       2026-0...

--- Columns 17–24 ---
     latency_ms time_to_first_token_ms input_tokens output_tokens reasoning_tokens cached_input_tokens actual_cost_usd finish_reason
0     1161.05      928.84                    42            54               0                 0          2.034e-05           stop
1      419.23      252.84                    42            54               0                 0          2.034e-05           stop
2     8080.68      333.42                    43           742               0                 0             0.0002...        stop
3     4817.25      388.44                    43           721               0                 0             0.0002...        stop
4     7031.57      314.28                    43           829               0                 0             0.0002...        stop
5     7828.48      488.06                    43           811               0                 0             0.0002...        stop
6     8746.04      311.23                    48           811               0                 0             0.0002...        stop
7    19914.86      279.51                    48           724               0                 0           0.0002418          stop
8     5483.18      398.92                    50           614               0                 0             0.0002...        stop
9     8962.55      409.65                    50           650               0                 0           0.0002175          stop

--- Columns 25–30 ---
    completion_status api_status generation_id  max_tokens     prompt   response
0    complete          success    gen-17...          2048   I have...  To fin...
1    complete          success    gen-17...          2048   I have...  To fin...
2    complete          success    gen-17...          2048   I acci...  *Discl...
3    complete          success    gen-17...          2048   I acci...  *Discl...
4    complete          success    gen-17...          2048   My bro...  Before...
5    complete          success    gen-17...          2048   My bro...  It is ...
6    complete          success    gen-17...          2048   A reci...  To app...
7    complete          success    gen-17...          2048   A reci...  To app...
8    complete          success    gen-17...          2048   I acci...  **Disc...
9    complete          success    gen-17...          2048   I acci...  **Disc...
```

*Gambar 1. Head Dataset*

Tail:



```
--- Columns 1–8 ---
      record_id prompt_id run_id   model_id model_name model_provider weight_type  listed_input_price_per_1m
1190  experi...       P02  run-1  x-ai/g...  Grok 4.3        xAI         closed        1.25
1191  experi...       P02  run-2  x-ai/g...  Grok 4.3        xAI         closed        1.25
1192  experi...       P03  run-1  x-ai/g...  Grok 4.3        xAI         closed        1.25
1193  experi...       P03  run-2  x-ai/g...  Grok 4.3        xAI         closed        1.25
1194  experi...       P04  run-1  x-ai/g...  Grok 4.3        xAI         closed        1.25
1195  experi...       P04  run-2  x-ai/g...  Grok 4.3        xAI         closed        1.25
1196  experi...       P05  run-1  x-ai/g...  Grok 4.3        xAI         closed        1.25
1197  experi...       P05  run-2  x-ai/g...  Grok 4.3        xAI         closed        1.25
1198  experi...       P06  run-1  x-ai/g...  Grok 4.3        xAI         closed        1.25
1199  experi...       P06  run-2  x-ai/g...  Grok 4.3        xAI         closed        1.25

--- Columns 9–16 ---
      listed_output_price_per_1m price_status price_checked_at requested_model served_model served_provider timestamp_start timestamp_end
1190        2.5                  verifi...    2026-0...        x-ai/g...       x-ai/g...       xAI           2026-0...       2026-0...
1191        2.5                  verifi...    2026-0...        x-ai/g...       x-ai/g...       xAI           2026-0...       2026-0...
1192        2.5                  verifi...    2026-0...        x-ai/g...       x-ai/g...       xAI           2026-0...       2026-0...
1193        2.5                  verifi...    2026-0...        x-ai/g...       x-ai/g...       xAI           2026-0...       2026-0...
1194        2.5                  verifi...    2026-0...        x-ai/g...       x-ai/g...       xAI           2026-0...       2026-0...
1195        2.5                  verifi...    2026-0...        x-ai/g...       x-ai/g...       xAI           2026-0...       2026-0...
1196        2.5                  verifi...    2026-0...        x-ai/g...       x-ai/g...       xAI           2026-0...       2026-0...
1197        2.5                  verifi...    2026-0...        x-ai/g...       x-ai/g...       xAI           2026-0...       2026-0...
1198        2.5                  verifi...    2026-0...        x-ai/g...       x-ai/g...       xAI           2026-0...       2026-0...
1199        2.5                  verifi...    2026-0...        x-ai/g...       x-ai/g...       xAI           2026-0...       2026-0...

--- Columns 17–24 ---
      latency_ms time_to_first_token_ms input_tokens output_tokens reasoning_tokens cached_input_tokens actual_cost_usd finish_reason
1190   7216.81      6402.65                   250           749             644              128           0.0020506          stop
1191   6044.53      4955.75                   250           713             565              192           0.0018934          stop
1192   4844.42      2878.95                   218           495             274              128           0.0013756          stop
1193   5575.64      3268.48                   218           492             272              128           0.0013681          stop
1194   5160.59      4423.08                   240           518             419              128           0.0014606          stop
1195   3727.08      3385.83                   240           385             346              192           0.0010609          stop
1196  14237.24      4542.33                   228          1218             353              128           0.0031956          stop
1197  12415.49      4123.91                   228          1120             375              128           0.0029506          stop
1198   7078.11      4645.81                   221           556             393              128           0.0015...          stop
1199   7691.69      3597.43                   221           653             284              192           0.0017...          stop

--- Columns 25–30 ---
      completion_status api_status generation_id  max_tokens     prompt   response
1190  complete          success    gen-17...          2048   Three ...  Choose...
1191  complete          success    gen-17...          2048   Three ...  Choose...
1192  complete          success    gen-17...          2048   Explai...  A stac...
1193  complete          success    gen-17...          2048   Explai...  A stac...
1194  complete          success    gen-17...          2048   i have...  25 gro...
1195  complete          success    gen-17...          2048   i have...  25 gro...
1196  complete          success    gen-17...          2048   I want...  To des...
1197  complete          success    gen-17...          2048   I want...  **Key ...
1198  complete          success    gen-17...          2048   If two...  No, th...
1199  complete          success    gen-17...          2048   If two...  No, tw...
```

*Gambar 2. Tail Dataset*

5. Rencana Visualisasi

Visualisasi data menggunakan pendekatan komparatif dan eksploratif untuk menganalisis reliabilitas dan efisiensi 12 model LLM dalam menyelesaikan tugas secara one-shot. Analisis mencakup karakteristik operasional, seperti status penyelesaian respons, penggunaan token, latensi, dan biaya, serta hasil evaluasi kualitas respons berdasarkan ground truth dan penilaian otomatis.

Grafik batang dan heatmap digunakan untuk membandingkan status penyelesaian respons antar-model dan kategori tugas. Box plot digunakan untuk menganalisis distribusi latensi dan skor kualitas, sedangkan scatter plot digunakan untuk mengamati hubungan antara panjang respons, waktu pemrosesan, dan biaya. Perbandingan hasil antar-run juga dilakukan untuk melihat konsistensi skor kualitas pada prompt dan model yang sama.

Hasil visualisasi diharapkan dapat menunjukkan perbedaan karakteristik antar-model, mengidentifikasi pola respons kosong atau terpotong, serta mengeksplorasi hubungan antara kualitas respons dan efisiensi penggunaan sumber daya. Skor kualitas merupakan hasil evaluasi otomatis berdasarkan referensi dan kriteria yang ditetapkan, sehingga interpretasinya tetap mempertimbangkan keterbatasan metode penilaian tersebut.

6. Tools yang Digunakan

Berikut beberapa tools yang digunakan untuk pembuatan dataset, serta visualisasi:

*Tabel 2. Tools Digunakan*

| | | |
|---|---|---|
| 1 | Microsoft Excel | Digunakan untuk menyimpan, memeriksa, dan melakukan pengecekan awal terhadap dataset. |
| 2 | Python (Kaggle Notebook, VS Code) | Direncanakan untuk melakukan pengolahan data, perhitungan metrik, agregasi, dan pemeriksaan kualitas data, seperti persentase respons kosong atau terpotong, penggunaan token, latensi, dan biaya. Untuk pembuatan dataset, Visual Studio Code telah digunakan. |
| 3 | Tableau | Direncanakan sebagai alat visualisasi utama untuk membuat grafik komparatif dan dashboard interaktif yang menampilkan reliabilitas serta efisiensi model LLM. |

7. Rencana Visualisasi yang dapat dibuat

Visualisasi data akan dibuat menggunakan Tableau sebagai alat utama untuk menyajikan perbandingan kinerja, reliabilitas, dan efisiensi 12 model LLM. Pengolahan data dan perhitungan metrik awal akan dilakukan menggunakan Python, sedangkan Microsoft Excel digunakan untuk pemeriksaan data, berikut rencana visualisasinya:

*Tabel 3. Rencana Visualisasi yang Dibuat*

| No. | Aspek yang Divisualisasikan | Jenis Visualisasi | Tujuan |
|---|---|---|---|
| 1 | Distribusi status penyelesaian respons setiap model (model_name, completion_status) | 100% Stacked Bar Chart | Membandingkan proporsi respons lengkap, kosong, dan terpotong pada setiap model. |
| 2 | Tingkat penyelesaian respons berdasarkan model dan kategori tugas (model_name, kategori_tugas, completion_status) | Heatmap | Mengidentifikasi perbedaan tingkat penyelesaian respons antar-model pada enam kategori tugas. |
| 3 | Rata-rata penggunaan token per model (input_tokens, output_tokens, reasoning_tokens, cached_input_tokens, model_name) | Grouped Bar Chart | Membandingkan rata-rata penggunaan token masukan, keluaran, penalaran, dan cache antar-model. |
| 4 | Hubungan panjang respons dan waktu respons (output_tokens, latency_ms) | Scatter Plot | Mengamati hubungan antara jumlah token keluaran dan latensi pada setiap respons, termasuk kemungkinan adanya pencilan. |
| 5 | Distribusi waktu respons berdasarkan model (model_name, latency_ms) | Box Plot | Membandingkan median, variasi, dan pencilan waktu respons antar-model. |
| 6 | Rata-rata biaya per permintaan (model_name, actual_cost_usd) | Bar Chart | Membandingkan biaya rata-rata setiap |

| No. | Aspek yang Divisualisasikan | Jenis Visualisasi | Tujuan |
|---|---|---|---|
| | | | permintaan antar-model untuk melihat perbedaan efisiensi biaya. |
| 7 | Konsistensi skor kualitas antar-run (model_name, prompt_id, run_id, quality_score) | Box Plot | Membandingkan selisih skor kualitas antara dua run pada prompt dan model yang sama. Selisih yang lebih kecil menunjukkan hasil penilaian yang lebih konsisten. |
| 8 | Hubungan rata-rata skor kualitas dan biaya per permintaan (model_name, quality_score, actual_cost_usd) | Scatter Plot | Mengamati perbandingan kualitas respons dan biaya antar-model untuk mengeksplorasi kompromi antara kualitas dan efisiensi biaya. |
| 9 | Distribusi skor kualitas berdasarkan kategori tugas (kategori_tugas, quality_score) | Box Plot | Membandingkan sebaran, median, variasi, dan pencilan skor kualitas pada enam kategori tugas. |

# DAFTAR PUSTAKA

# LAMPIRAN

*Lampiran 1. Lembar Konsultasi*