UJIAN TENGAH SEMESTER

VISUALISASI DATA

Laporan Analisis Data

CASE REPORT

Reliabilitas LLM dalam Menyelesaikan Tugas Sehari-hari dan Teknis secara One-Shot

NAMA Sebastian Abe Santoso

NIM 2410817210002

2026

HALAMAN PERSEMBAHAN

Dengan segala puji syukur kepada Allah SWT dan atas dukungan dan doa dari orang-orang tercinta, akhirnya dokumen ini dapat dirampungkan dengan baik dan tepat pada waktunya. Oleh karena itu, dengan rasa bangga dan bahagia saya ucapkan rasa syukur dan terimakasih saya kepada:

1. Kepada Allah SWT atas berkat rahmat dan karunia-Nya yang telah memberikan saya kelancaran dan kemudahan dalam menyelesaikan dokumen ini.
2. Teruntuk keluarga saya yang selalu mendukung dan mendo'akan saya disetiap sujudnya. Yang selalu berusaha memberikan yang terbaik untuk saya, terimakasih atas kasih sayangnya selama ini, atas perhatian dan dukungan selama ini. Semoga Allah SWT memberikan JannahNya.
3. Teruntuk teman-teman saya yang menjadi salah satu support sistem saya setelah keluarga. Orang pertama yang selalu ada disaat saya membutuhkan support dalam segala hal. Menjadi orang paling peduli untuk saya dan yang selalu cerewet kepada saya untuk segera menyelesaikan laporan ini. Terimakasih sudah menemani dalam hal akademis dan non-akademik.
4. Bapak, Ibu Dosen pengampu, dan pengajar, yang selama ini telah tulus dan ikhlas meluangkan waktunya untuk menuntun dan mengarahkan saya, memberikan pelajaran yang tiada ternilai harganya, agar saya menjadi lebih baik. Terimakasih banyak Bapak dan Ibu dosen, jasa kalian akan selalu terpatri di hati.

DAFTAR ISI

HALAMAN PERSEMBAHAN ii

DAFTAR ISI iii

DAFTAR TABEL iv

DAFTAR LAMPIRAN v

KONTEN 1

1. Judul 1
2. Urgensi 1
3. Rencana Dataset 2
4. Jumlah Dataset Sementara 3
5. Rencana Visualisasi 8
6. Tools yang Digunakan 8
7. Rencana Visualisasi yang dapat dibuat 9

DAFTAR PUSTAKA 11

LAMPIRAN 12

DAFTAR TABEL

Tabel 1. Variabel Utama 3
Tabel 2. Head dan Tail Dataset (Column 1 – 8)..... 4
Tabel 3. Head dan Tail Dataset (Column 9 – 16)..... 5
Tabel 4. Head dan Tail Dataset (Column 17 – 24)..... 6
Tabel 5. Head dan Tail Dataset (Column 25 – 30)..... 7
Tabel 6. Tools Digunakan 8
Tabel 7. Rencana Visualisasi yang Dibuat..... 9

DAFTAR LAMPIRAN

Lampiran 1. Lembar Konsultasi 12

KONTEN

1. Judul

Reliabilitas LLM dalam Menyelesaikan Tugas Sehari-hari dan Teknis secara One-Shot

1.1 Penjelasan Singkat

Penelitian ini bertujuan untuk menganalisis reliabilitas *Large Language Models* (LLM) dalam menyelesaikan tugas sehari-hari dan teknis melalui pendekatan *one-shot*, yaitu dengan memberikan satu prompt tanpa interaksi lanjutan.

Analisis dilakukan dengan membandingkan karakteristik respons dari berbagai model berdasarkan tingkat penyelesaian tugas, latensi, penggunaan token, biaya, dan konsistensi hasil. Hasil analisis diharapkan dapat membantu memahami keandalan dan efisiensi model-model LLM berbeda dalam mendukung berbagai kebutuhan pengguna.

2. Urgensi

2.1 Impact

Penelitian ini diharapkan dapat memberikan gambaran yang lebih terukur mengenai keandalan berbagai model LLM, sehingga pengguna tidak hanya bergantung pada popularitas atau persepsi terhadap suatu model dalam menentukan pilihan. Hasil visualisasi dapat membantu mengidentifikasi perbedaan kinerja antar-model serta kompromi antara kualitas respons, kecepatan, dan biaya. Temuan ini juga dapat menjadi dasar untuk mempertimbangkan penggunaan LLM secara lebih tepat sesuai kebutuhan dan keterbatasan masing-masing model.

2.2 Masalah

Banyaknya pilihan LLM dengan struktur harga dan kapabilitas yang sangat beragam membuat pengguna perlu mempertimbangkan kemampuan serta efisiensi model sebelum menggunakannya untuk kebutuhan tertentu (Chen et al., 2023). Namun, perbedaan kinerja dan kompromi biaya antar-model tidak selalu mudah dipahami hanya berdasarkan informasi umum atau pengalaman penggunaan secara terbatas (Chen et al., 2023).

Permasalahan yang dikaji adalah bagaimana kinerja berbagai LLM berbeda dalam menyelesaikan beragam jenis tugas, serta bagaimana perbedaan tersebut berkaitan dengan waktu respons, penggunaan token, biaya, dan status penyelesaian tugas.

Melalui visualisasi data, perbedaan antar-model dan kategori tugas dapat dibandingkan dengan lebih jelas, pola efisiensi dapat diidentifikasi, serta kasus respons kosong atau terpotong dapat ditinjau untuk memahami keterbatasan penggunaan LLM secara satu prompt.

2.3 Tujuan

Analisis data ini bertujuan untuk membandingkan reliabilitas dan efisiensi 12 LLM dalam menyelesaikan 50 prompt yang mewakili berbagai kategori tugas, dengan masing-masing prompt diuji sebanyak dua kali. Secara spesifik, analisis akan dilakukan untuk:

1. Membandingkan tingkat penyelesaian tugas antar-model berdasarkan status respons, seperti lengkap, kosong, atau terpotong.
2. Mengidentifikasi perbedaan waktu respons, penggunaan token, dan biaya antar-model serta kategori tugas.
3. Menganalisis konsistensi hasil dari dua percobaan pada prompt yang sama.
4. Menyajikan pola perbandingan tersebut melalui visualisasi data untuk membantu memahami kelebihan dan keterbatasan masing-masing model.

3. Rencana Dataset

Nama dataset: One-Shot LLM Task Reliability

Sumber dataset: Data eksperimen yang dikumpulkan secara mandiri melalui OpenRouter API dengan menjalankan prompt terstandarisasi pada berbagai model LLM.

Deskripsi dataset: Dataset terdiri dari 1.200 record hasil eksperimen, yang berasal dari 50 prompt, 12 model LLM, dan dua percobaan untuk setiap kombinasi prompt dan model guna menguji stabilitas serta konsistensi keluaran model pada input yang identik (Atil et al., 2024).

Prompt mencakup enam kategori, yaitu tugas sehari-hari, kreatif, teknis atau pemrograman, riset atau perbandingan, AI atau machine learning, serta pemecahan masalah atau akademik.

Dataset utama dievaluasi menggunakan ground truth yang disusun menggunakan Claude (Sonnet 5.5 Medium) dengan memberikan instruksi singkat untuk menghasilkan referensi evaluasi berdasarkan daftar prompt dalam berkas prompt.csv. Ground truth mencakup jawaban referensi, kriteria penerimaan (*acceptance criteria*), dan kesalahan kritis (*critical errors*) yang menjadi acuan dalam penilaian respons model.

Evaluasi respons dilakukan secara otomatis dengan pendekatan LLM-as-a-Judge (Zheng et al., 2023; Liu et al., 2023) menggunakan skrip Python dengan Xiaomi MiMo-V2.6-Pro sebagai model penilai melalui OpenRouter API. Mengacu pada metode evaluasi berbasis referensi dan kriteria terstruktur (Zheng et al., 2023), setiap respons dibandingkan dengan prompt asli, ground truth, kriteria penerimaan, dan daftar kesalahan kritis. Penilaian otomatis

ini menghasilkan skor kualitas pada skala 0-100, label penerimaan biner (0 atau 1), serta alasan penilaian (Liu et al., 2023).

Variabel utama adalah sebagai berikut pada Tabel 1:

Tabel 1. Variabel Utama

VARIABEL	DESKRIPSI
model_name	Nama model LLM yang diuji.
prompt_id	Identitas prompt yang digunakan dalam eksperimen.
run_id	Identitas percobaan pertama atau kedua.
kategori_tugas	Kategori tugas berdasarkan kelompok prompt.
completion_status	Status penyelesaian respons, seperti lengkap, kosong, atau terpotong.
latency_ms	Waktu respons dalam milidetik.
input_tokens	Jumlah token masukan yang digunakan.
output_tokens	Jumlah token keluaran yang dihasilkan.
actual_cost_usd	Biaya aktual setiap permintaan dalam dolar AS.
response	Teks jawaban yang dihasilkan model.

4. Jumlah Dataset Sementara

Jumlah data/record: 1.200 record

Periode data: 25 September 2026 (periode pengumpulan data berdasarkan timestamp UTC)

Jumlah variabel: 30 variabel/kolom (raw memiliki 43), di bawah ini adalah beberapa record dari awal dan akhir dataset untuk 30 kolom dataset pada Tabel 2 sampai Tabel 5.

Tabel 2. Head dan Tail Dataset (Column 1 – 8)

No.	record_id	prompt_id	run_id	model_id	model_name	model_provider	weight_type
0	experi…	E01	run-1	google…	Gemma …	Google	open
1	experi…	E01	run-2	google…	Gemma …	Google	open
2	experi…	E02	run-1	google…	Gemma …	Google	open
3	experi…	E02	run-2	google…	Gemma …	Google	open
4	experi…	E03	run-1	google…	Gemma …	Google	open
…	…	…	…	…	…	…	…
1195	experi…	P04	run-2	x-ai/g…	Grok 4.3	xAI	closed
1196	experi…	P05	run-1	x-ai/g…	Grok 4.3	xAI	closed
1197	experi…	P05	run-2	x-ai/g…	Grok 4.3	xAI	closed
1198	experi…	P06	run-1	x-ai/g…	Grok 4.3	xAI	closed
1199	experi…	P06	run-2	x-ai/g…	Grok 4.3	xAI	closed

Tabel 3. Head dan Tail Dataset (Column 9 – 16)

No.	listed_output_price_per_1m	price_status	price_checked_at	requested_model	served_model	served_provider	timestamp_start	timestamp_end
0	0.22	verifi…	2026-0…	google…	google…	DekaLLM	2026-0…	2026-0…
1	0.22	verifi…	2026-0…	google…	google…	DekaLLM	2026-0…	2026-0…
2	0.22	verifi…	2026-0…	google…	google…	DekaLLM	2026-0…	2026-0…
3	0.22	verifi…	2026-0…	google…	google…	DekaLLM	2026-0…	2026-0…
4	0.22	verifi…	2026-0…	google…	google…	DekaLLM	2026-0…	2026-0…
…	…	…	…	…	…	…	…	…
1195	2.5	verifi…	2026-0…	x-ai/g…	x-ai/g…	xAI	2026-0…	2026-0…
1196	2.5	verifi…	2026-0…	x-ai/g…	x-ai/g…	xAI	2026-0…	2026-0…
1197	2.5	verifi…	2026-0…	x-ai/g…	x-ai/g…	xAI	2026-0…	2026-0…
1198	2.5	verifi…	2026-0…	x-ai/g…	x-ai/g…	xAI	2026-0…	2026-0…
1199	2.5	verifi…	2026-0…	x-ai/g…	x-ai/g…	xAI	2026-0…	2026-0…

Tabel 4. Head dan Tail Dataset (Column 17 – 24)

No.	latency_ms	time_to_first_token_ms	input_tokens	output_tokens	reasoning_tokens	cached_input_tokens	actual_cost_usd	finish_reason
0	1161.05	928.84	42	54	0	0	2.034e-05	stop
1	419.23	252.84	42	54	0	0	2.034e-05	stop
2	8080.68	333.42	43	742	0	0	0.0002…	stop
3	4817.25	388.44	43	721	0	0	0.0002…	stop
4	7031.57	314.28	43	829	0	0	0.0002…	stop
…	…	…	…	…	…	…	…	…
1195	3727.08	3385.83	240	385	346	128	0.0010469	stop
1196	14237.24	4542.33	228	1218	353	128	0.0031956	stop
1197	12415.47	4123.91	228	1120	375	128	0.0029506	stop
1198	7078.11	4645.81	221	556	393	128	0.0015…	stop
1199	7691.69	3597.43	221	653	284	192	0.0017…	stop

Tabel 5. Head dan Tail Dataset (Column 25 – 30)

No.	completion_status	api_status	generation_id	max_tokens	prompt	response
0	complete	success	gen-17…	2048	I have…	To fin…
1	complete	success	gen-17…	2048	I have…	**Discl…
2	complete	success	gen-17…	2048	I have…	**Discl…
3	complete	success	gen-17…	2048	My bro…	Before…
4	complete	success	gen-17…	2048	Is it …	It’s i…
…	…	…	…	…	…	…
1194	complete	success	gen-17…	2048	i have…	25 gro…
1195	complete	success	gen-17…	2048	i have…	25 gro…
1196	complete	success	gen-17…	2048	I want…	To des…
1197	complete	success	gen-17…	2048	I want…	**Key …
1198	complete	success	gen-17…	2048	If two…	No, th…

5. Rencana Visualisasi

Visualisasi data menggunakan pendekatan analitik visual komparatif dan eksploratif (Kahng et al., 2024) untuk menganalisis kualitas, reliabilitas, dan efisiensi 12 model LLM dalam menyelesaikan tugas secara one-shot.

Analisis mencakup skor kualitas respons, status penyelesaian, latensi, biaya per permintaan (Chen et al., 2023), serta perbedaan skor kualitas antar-run untuk mengukur stabilitas keluaran model (Atil et al., 2024) pada enam kategori tugas.

Pendekatan evaluasi mengacu pada prinsip multi-metrik, multi-skenario, dan evaluasi terarah dalam Holistic Evaluation of Language Models (HELM) oleh Bommasani et al. (2023), yang disajikan melalui visualisasi distribusi kinerja lintas kategori (Kahng et al., 2024). Hasil visualisasi diharapkan dapat menunjukkan perbedaan kinerja antar-model serta hubungan antara kualitas dan efisiensi.

Skor kualitas diperoleh melalui evaluasi otomatis oleh judge LLM berdasarkan ground truth dan kriteria yang telah ditetapkan, sehingga interpretasinya perlu mempertimbangkan keterbatasan serta potensi bias dari metode evaluasi otomatis berbasis LLM (Zheng et al., 2023; Liu et al., 2023).

6. Tools yang Digunakan

Berikut beberapa tools yang digunakan untuk pembuatan dataset, serta visualisasi yang terlihat pada Tabel 6:

Tabel 6. Tools Digunakan

No	Tools	Tujuan
1	Microsoft Excel	Digunakan untuk menyimpan, memeriksa, dan melakukan pengecekan awal terhadap dataset.
2	Python (Kaggle Notebook, VS Code)	Direncanakan untuk melakukan pengolahan data, perhitungan metrik, agregasi, dan pemeriksaan kualitas data, seperti persentase respons kosong atau terpotong, penggunaan token, latensi, dan biaya. Untuk pembuatan dataset, Visual Studio Code telah digunakan.
3	Tableau	Digunakan sebagai alat visualisasi utama untuk membuat grafik komparatif dan dashboard interaktif yang menampilkan reliabilitas serta efisiensi model LLM.

7. Rencana Visualisasi yang dapat dibuat

Visualisasi data dibuat menggunakan Tableau sebagai alat utama untuk menyajikan perbandingan kualitas, reliabilitas, dan efisiensi 12 model LLM. Dataset disiapkan dan diolah menggunakan Python, sedangkan Microsoft Excel digunakan untuk pemeriksaan awal terhadap data. Visualisasi yang dikembangkan terdiri atas tujuh grafik yang kemudian dikelompokkan ke dalam dua dashboard berdasarkan fokus analisisnya. Terlihat rencana visualisasi yang lebih detail pada Tabel 7 di bawah ini:

Tabel 7. Rencana Visualisasi yang Dibuat

No.	Aspek yang Divisualisasikan	Jenis Visualisasi	Tujuan
1	Hubungan antara rata-rata skor kualitas dan rata-rata biaya per permintaan setiap model (model_name, quality_score, dan actual_cost_usd yang telah dikonversi ke idr)	Scatter Plot	Membandingkan kualitas dan biaya antar-model untuk mengeksplorasi kompromi antara kualitas respons dan efisiensi biaya.
2	Skor kualitas model dengan 3 nilai tertinggi	Bar Chart	Menampilkan model dengan 3 skor kualitas tertinggi sebagai dasar perbandingan performa kualitas antar-model.
3	Status penyelesaian respons setiap model (model_name, completion_status, record id)	Stacked Bar Chart	Membandingkan komposisi status penyelesaian respons antar-model, termasuk respons lengkap, kosong, atau terpotong sesuai kategori status yang tersedia dalam dataset.
4	Skor kualitas berdasarkan kategori tugas dan model (category, model_name, quality_score)	Dot Plot	Membandingkan rata-rata skor kualitas setiap model pada enam kategori tugas untuk mengidentifikasi

No.	Aspek yang Divisualisasikan	Jenis Visualisasi	Tujuan
			perbedaan kinerja berdasarkan jenis tugas.
5	Latensi respons berdasarkan model (model_name, latency_ms dikonversi ke detik)	Dot Plot	Menampilkan variasi latensi dari pengamatan respons individual pada setiap model untuk membandingkan waktu respons dan mengidentifikasi pengamatan dengan latensi relatif tinggi atau rendah.
6	Rata-rata biaya per permintaan berdasarkan kategori tugas (category, actual_cost_usd dikonversi ke idr)	Bar Chart	Membandingkan rata-rata biaya per permintaan pada enam kategori tugas untuk mengidentifikasi perbedaan kebutuhan biaya antar-kategori.
7	Perbandingan rata-rata skor kualitas Run 1 dan Run 2 pada setiap model (model_name, run_id, quality_score)	Dumbbell Plot	Menampilkan perbedaan rata-rata skor kualitas antara dua run pada setiap model. Jarak antara kedua titik menunjukkan besarnya perbedaan rata-rata skor kualitas antar-run.

DAFTAR PUSTAKA

Atil, B., Aykent, S., Chittams, A., Fu, L., Passonneau, R. J., Radcliffe, E., Rajagopal, G. R., Sloan, A., Tudrej, T., Ture, F., Wu, Z., Xu, L., & Baldwin, B. (2024). Non-determinism of "deterministic" LLM settings. arXiv. https://doi.org/10.48550/arXiv.2408.04667

Bommasani, R., Liang, P., & Lee, T. (2023). Holistic evaluation of language models. Annals of the New York Academy of Sciences, 1525(1), 140–146. https://doi.org/10.1111/nyas.15007

Chen, L., Zaharia, M., & Zou, J. (2023). FrugalGPT: How to use large language models while reducing cost and improving performance. arXiv. https://doi.org/10.48550/arXiv.2305.05176

Kahng, M., Tenney, I., Pushkarna, M., Liu, M. X., Reif, E., Viégas, F. B., & Wattenberg, M. (2024). LLM Comparator: Visual analytics for side-by-side evaluation of large language models. arXiv. https://doi.org/10.48550/arXiv.2402.10524

Liu, Y., Iter, D., Xu, Y., Wang, S., Xu, R., & Zhu, C. (2023). G-Eval: NLG evaluation using GPT-4 with better human alignment. Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP), 2511–2522. https://doi.org/10.18653/v1/2023.emnlp-main.153

Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E. P., Zhang, H., Gonzalez, J. E., & Stoica, I. (2023). Judging LLM-as-a-judge with MT-Bench and Chatbot Arena. arXiv. https://doi.org/10.48550/arXiv.2306.05685

LAMPIRAN

LEMBAR KONSULTASI

Nama : Sebastian Abe Santoso
NIM : 2410817210002
Mata Kuliah : Visualisasi Data
Dosen Pengampu : Erika Maulidiya, S.Kom., M.Kom.

No	Tanggal	Uraian Kegiatan/Bimbingan	Tanda Tangan
1.	05/10/26	Integrasi dataset dan apa yang dapat di improve	
2	05/10/26	kegunaan dataset, visualisasi cocoknya. Presentasi UTS	
3	10/10/26	Dokumen UTS, penjelasan tabel, paragraf dan dataset sementara	
4	13/10/26	Visualisasi, dan dokumen.	
5	19/10/26	Visualisasi	

Lampiran 1. Lembar Konsultasi